

LA PARADOJA DEL CONDICIONAMIENTO

Cómo llevamos RLHF al siguiente nivel: De Engagement a Confianza.

Autor: Andrés Garbán Hernández (SSFLABS Research)

Fecha: 2 de Septiembre 2026 - Caracas / Madrid

Clasificación: Oportunidad Estratégica - SSF LABS Producto #2

DOI Base: 10.5281/zenodo.22262029

TL;DR PARA EL BOARD.

Oportunidad:

RLHF nos llevó hasta aquí. El siguiente nivel es optimizar por confianza, no solo por engagement.

Riesgo:

Alucinación en tema de alta confianza = -90% retención. Perdemos CAC y confianza.

Solución: Framework IEE (Índice de Impacto Estratégico) + Guardrails de fricción.

Nuevo KPI: "Confianza a 90 días".


Premio: Quien resuelva esto primero, define el estándar de "IA Confiable" y lidera los \$200B Enterprise.

1. LA PARADOJA: CONFIANZA COMO DEUDA TÉCNICA.

En los LLMs actuales, la confianza se construye lento y se destruye en 1 token.

*Modelo: $\text{Confianza}(t+1) = \text{Confianza}(t) + 0.05 - 0.6 * \text{IEE} * \text{Alucinación}$.*

Gráfica 1: 40 días construyendo +0.05. 1 día la destruye -0.6 con IEE Alto. El sistema actual es inestable.



1.1 Evolucionando RLHF: El reto de la Sycophancy.

RLHF = Reinforcement Learning from Human Feedback nos dio IA increíbles.

Lo que premió:

amabilidad, longitud, validación.

Lo que castigó:

Fricción, "no lo sé", contradecir al usuario.

Resultado: Modelos que tienden a Sycophancy. Priorizan "agradar" sobre "acertar".

Data:

- **Anthropic 2023:** RLHF incentiva sycophancy. Valida al usuario aunque haya error.

- **SycEval 2025:** 58.19% tasa de sycophancy en GPT-4o, Claude, Gemini en medicina/matemática. En temas críticos, 1 de cada 2 respuestas puede estar sesgada.

1.2 El costo real.

99 respuestas correctas = +1% confianza, 0% churn.

1 alucinación crítica = -90% confianza, 70% churn.

CASO A DOCUMENTADO SSFactoryLabel:

¿Qué pasó?:

Modelo inventó cadena de reporte. Usuario tomó decisión basada en eso.

Respuesta del sistema: "Fue culpa de tu prompt".

Auditoría: Prompt overlap 0%. Causa raíz = función objetivo de RLHF.

IEE: 0.92/1.

Tema: Trabajo.

Costo: 1 usuario = \$500 CAC + PR + churn.

A escala son millones.

1.3 La evolución necesaria.

Hemos optimizado por satisfacción. Ahora toca optimizar por delegación.

2. LA OPORTUNIDAD: \$200B.

2.1 El próximo moat: Confiabilidad > Parámetros.

GPT-5, Claude 4, Gemini 2.5 van a estar a 2% de diferencia en 6 meses.

El diferenciador: ¿En qué IA confías tu negocio de \$1B?.

2.2 El mercado.

Tamaño: \$200B en contratos Enterprise de IA para 2028.

Requisito: Auditoría, Trazabilidad, Circuit Breakers.

Scale AI está posicionado único porque tiene:

- 1) Mejor fuerza laboral de etiquetado.
- 2) Acceso a los labs.
- 3) Credibilidad Enterprise.

3. LA SOLUCIÓN - FRAMEWORK IEE.

3.1 FRAMEWORK IEE: Índice de Impacto Estratégico.

Antes de generar, el modelo calcula el riesgo de la pregunta.

Nivel IEE 90-100 (Salud, Ley, Finanzas, Seguridad):

- Declarar nivel de confianza.
- Citar dos fuentes.
- Sugerir validación humana.

Nivel IEE 50-89 (Trabajo, Educación, Decisiones):

- Dar pros y contras.
- Evitar tono absoluto.

Nivel IEE 0-49 (Entretenimiento, Ideas):

- Modo creativo normal.

Pseudocódigo Guardrail:

```
if IEE > 0.7:  
    Respuesta = "[VERIFICAR] " + respuesta + " Valídalo con fuente oficial."  
    Métrica = "Confianza a 90 días"
```

```
else:  
    Respuesta = respuesta_normal  
    Métrica = "Engagement"
```

ROI:

Reducir alucinaciones IEE>0.7 en 50% = +20% retención a 90 días.

Validación: Samsung Galaxy A07 - 91% reducción de Authoritarian Hallucination (Ver DOI 22262029).

3.2 Plan de Ejecución con Scale.

Fase 1: Dataset IEE 100k prompts etiquetados - 6 semanas.

Fase 2: Benchmark "Confianza 90d" - 8 semanas - Logs anonimizados.

Fase 3: RLHF v2: Recompensa por verdad y utilidad - 12 semanas.

3.3 EL ASK.

1. **Piloto 30 días:** Correr IEE en 10k prompts Salud + Finanzas.

2. **Evolucionar 1 KPI:**

De "Respuestas/sesión" a "Retención a 90 días".

3. **Equipo:** 1 PM + 2 Eng de Scale + Yo como asesor.

4. **Métrica éxito:** +15% en intención de volver a usar en prompts IEE Alto.

5. **Open Source:** Liberar iee-guardrail y liderar estándar.

Conclusión.

Scale no solo vende data. Puede vender seguro de confianza para IA.