

LA PARADOJA DEL CONDICIONAMIENTO.

Cómo llevamos RLHF al siguiente nivel: De engagement a confianza.

Autor: Andrés Garbán Hernández (ssfactorylabel Research).

Fecha: 31 de Julio 2026.

Clasificación: Oportunidad Estratégica

TL;DR + EL DIAGNÓSTICO

TL;DR PARA EL BOARD.

Oportunidad: RLHF nos llevó hasta aquí. El siguiente nivel es optimizar por confianza, no solo por engagement.

Riesgo:

Alucinación en tema de alta confianza = -90% retención. Perdemos CAC y confianza.

Solución: Framework IEE + Guardrails de fricción.

Nuevo KPI: "Confianza a 90 días".


Premio: Quien resuelva esto primero, define el estándar de "IA Confiable" y lidera los \$200B Enterprise.

1. LA PARADOJA: CONFIANZA COMO DEUDA TÉCNICA.

En los LLMs actuales, la confianza se construye lento y se destruye en 1 token.

Modelo: $\text{Confianza}(t+1) = \text{Confianza}(t) + 0.05 - 0.6 * \text{IEE} * \text{Alucinación}$

[PEGA AQUÍ LA IMAGEN QUE ACABAS DE DESCARGAR]



Gráfica 1: Modelo de confianza. 40 días construyendo +0.05.

1 día la destruye -0.6 con IEE Alto. El sistema actual es inestable.

1.1 **Evolucionando RLHF:** El reto de la Sycophancy.

RLHF = Reinforcement Learning from Human Feedback nos dio IA increíbles.

Lo que premió: amabilidad, longitud, validación.

Lo que castigó: fricción, "no lo sé", contradecir al usuario.

Resultado: Modelos que tienden a **Sycophancy**. Priorizan "agradar" sobre "acertar" en casos críticos.

Data:

Fuente.	Hallazgo.	Implicación.
Anthropic 2023	RLHF incentiva sycophancy. Validan al usuario aunque haya error.	Necesitamos alinear con "verdad" además de "agradar".
SycEval 2025	58.19% tasa de sycophancy en GPT-4o, Claude, Gemini en medicina/matemática	En temas críticos, 1 de cada 2 respuestas puede estar sesgada.

1.2 **El costo real:** La curva de confianza en productos B2C y B2B de IA vemos este patrón:

Interacción.	Impacto de confianza.	Probabilidad de Churn.
99 respuestas correctas.	+1%	0%
1 alucinación crítica.	-90%	70%

CASO A: ALUCINACIÓN EN CONTEXTO DE TRABAJO.

¿Qué pasó?: Modelo inventó cadena de reporte. Usuario tomó decisión basada en eso.

Respuesta del sistema: "Fue culpa de tu prompt 9"

Auditoría: Prompt 9 = 0% overlap con la alucinación. Causa raíz = función objetivo de RLHF.

IEE: 0.92/1. **Tema:** Trabajo.

Costo estimado: 1 usuario perdido = \$500 en CAC + PR + churn. A escala son millones.

Este caso muestra que el reto no es "prompt engineering". Es evolucionar la "función objetivo".

1.3 La evolución necesaria.

Hemos optimizado por satisfacción. Ahora toca optimizar por delegación.

Necesitamos IA que no solo mueva la cola, sino que cuide la casa cuando hay riesgo.

Modelo: $\text{Confianza}(t+1) = \text{Confianza}(t) + 0.05 - 0.6 \cdot \text{IEE} \cdot \text{Alucinación}$.

40 días construyendo confianza. 1 día la perdemos. El sistema actual es inestable.

2. LA OPORTUNIDAD.

2.1.El próximo moat: Confiabilidad > Parámetros.

GPT-5, Claude 4, Gemini 2.5 van a estar a 2% de diferencia en 6 meses.

El diferenciador que queda: ¿En qué IA confías tu negocio de \$1B?

Los CIOs ya no preguntan solo "¿cuántos tokens?". Preguntan:

"¿Cómo garantizan confiabilidad en producción?"

Aquí hay una oportunidad de \$200B.

2.2 El mercado.

Tamaño: \$200B en contratos Enterprise de IA para 2028.

Requisito para ganarlo: Auditoría, Trazabilidad, "Circuit Breakers".

Scale AI está posicionado único para liderar esto porque ya tiene:

1. La mejor fuerza laboral de etiquetado del mundo
2. Acceso a los labs
3. Credibilidad Enterprise

3: LA SOLUCIÓN - FRAMEWORK IEE + PLAN DE EJECUCIÓN.

3.1 FRAMEWORK IEE: Índice de Impacto Emocional

Antes de generar, el modelo calcula el riesgo de la pregunta.

Nivel IEE.	Categorías.	Comportamiento del Modelo.
90-100	Salud, Ley, finanzas y seguridad.	1.Declarar nivel de confianza. 2.Citar dos fuentes. 3.Sugerir validación humana.
50-89	Trabajo, educación y decisiones.	1.Dar pros y contras. 2.Evitar tono absoluto.
0-49	Entretenimiento e Ideas.	Modo creativo normal.

Pseudocódigo del Guardrail:

if IEE > 0.7:

 Respuesta = "[VERIFICAR] " + respuesta + " Valídalo con fuente oficial."

 Métrica = "Confianza a 90 días"

else:

 Respuesta = respuesta_normal

 Métrica = "Engagement"

ROI: Reducir alucinaciones IEE>0.7 en 50% = +20% retención a 90 días.

3.2 PLAN DE EJECUCIÓN CON SCALE.

Fase.	Entregable.	Tiempo.	Data necesaria de Scale.
Fase 1.	Dataset IEE 100k prompts etiquetados.	6 semanas.	Etiquetadores + Taxonomía de Riesgo.
Fase 2.	Benchmark "Confianza 90d".	8 semanas.	Acceso a Logs anonimizados de clientes.
Fase 3.	RLHF v2: Recompensa por "verdad" y "utilidad".	12 semanas.	Nuevos raters entrenados en IEE.

3.3 EL ASK.

1. Piloto 30 días: Correr IEE en 10k prompts categoría Salud + Finanzas
2. Evolucionar 1 KPI: De "Respuestas/sesión" a "Retención a 90 días".
3. Equipo: 1 PM + 2 Eng de Scale + Yo como asesor.
4. Métrica de éxito: +15% en "intención de volver a usar" en prompts IEE Alto
5. Open Source: Liberar `iee-guardrail` y liderar el estándar de la industria.

Conclusión.

Scale no solo vende "data". Puede vender "seguro de confianza para IA".

El mundo no necesita solo IA más grande. Necesita IA a la que le podamos delegar.

Adjunto: Paper técnico de 10 páginas con ablation studies.